QUY TRÌNH CHUẨN BỊ DỮ LIỆU VÀ XỬ LÝ NHÃN CẤU TRÚC

Nhóm 4

Tháng 8 năm 2026

Tóm tắt nội dung

Báo cáo trình bày quy trình chuẩn bị tập dữ liệu gồm tám văn bản quy phạm pháp luật trong lĩnh vực lao động và bảo hiểm xã hội. Quy trình bao gồm lựa chọn nguồn dữ liệu, trích xuất lớp văn bản hoặc nhận dạng ký tự quang học, làm sạch nội dung, khôi phục cấu trúc pháp lý, xử lý nhãn cấu trúc bị nhiễu, chia đoạn theo cấu trúc và gắn siêu dữ liệu. Kết quả thu được 668 đoạn dữ liệu ở định dạng JSON Lines từ 476 trang PDF. Toàn bộ tám văn bản đều có dữ liệu, không có định danh đoạn trùng lặp và không có đoạn rỗng.

Mục lục

1 Mục tiêu và phạm vi **3**

2 Tổng quan quy trình **3**

3 Chuẩn bị và trích xuất dữ liệu **4**

3.1 Kiểm tra lớp văn bản 4

3.2 Kiểm soát lỗi trích xuất 4

4 Làm sạch và chuẩn hóa văn bản **4**

4.1 Loại bỏ nhiễu trình bày 4

4.2 Chuẩn hóa ký tự và khoảng trắng 4

5 Khôi phục cấu trúc và xử lý nhãn **5**

5.1 Nhận diện cấu trúc phân cấp 5

5.2 Các nhãn cấu trúc được thiết lập 5

5.3 Chuẩn hóa nhãn bị nhiễu do OCR 6

5.4 Loại nhãn Điều giả 6

6 Chia đoạn theo cấu trúc và gắn metadata **6**

6.1 Schema metadata của mỗi chunk 6

6.2 Ý nghĩa các nhãn chunk 8

7 Kết quả và kiểm soát chất lượng **8**

8 Hạn chế của dữ liệu **9**

9 Kết luận **9**

1 Mục tiêu và phạm vi

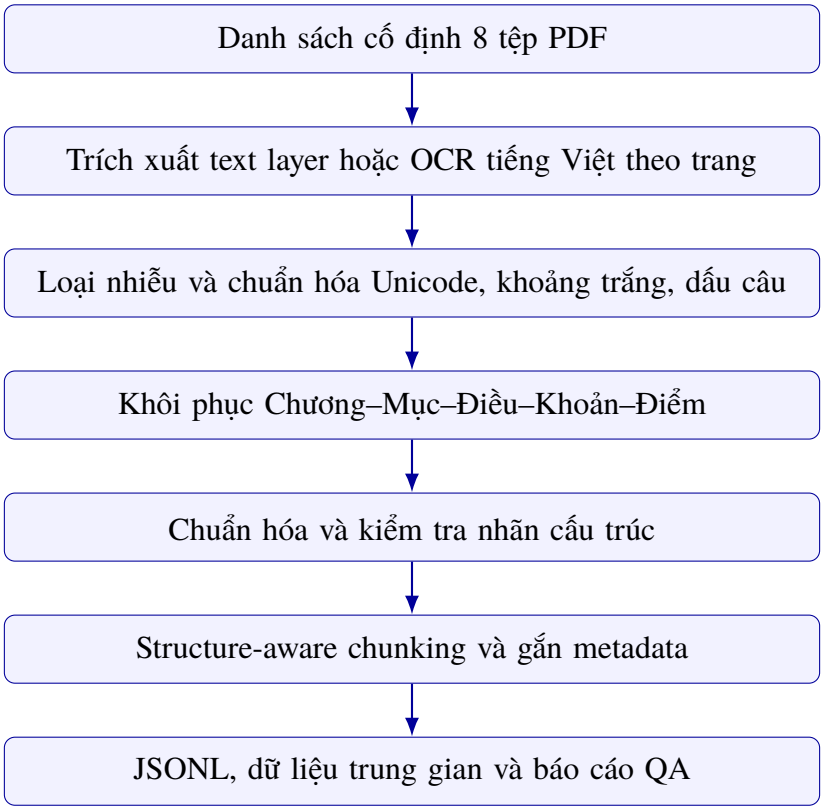
Mục tiêu của bước chuẩn bị dữ liệu là chuyển các văn bản pháp luật ở định dạng PDF thành tập dữ liệu có cấu trúc, phù hợp cho các bước phân tích hoặc huấn luyện mô hình về sau. Khác với tài liệu thông thường, ý nghĩa của một đoạn văn bản luật phụ thuộc mạnh vào vị trí của nó trong Chương, Mục, Điều, Khoản và Điểm. Vì vậy, quy trình không chia văn bản hoàn toàn theo độ dài cố định mà ưu tiên bảo toàn đơn vị pháp lý và ngữ cảnh phân cấp.

Tập đầu vào gồm đúng tám tệp PDF được đánh số từ 01 đến 08 trong thư mục `data`. Ba tài liệu trong thư mục `data/tuychon` không được sử dụng. Danh sách đầu vào được khai báo tường minh thay vì quét thư mục đệ quy, nhờ đó kết quả có thể tái lập và không bị thay đổi khi xuất hiện tệp ngoài phạm vi.

Trong báo cáo này, "nhãn" được hiểu là nhãn cấu trúc và nhãn siêu dữ liệu gắn cho đơn vị nội dung, chẳng hạn số Điều, danh sách Khoản, danh sách Điểm, loại đoạn và vị trí trang nguồn. Đây không phải là nhãn dự đoán nội dung pháp lý do con người gán thủ công.

2 Tổng quan quy trình

Quy trình được tổ chức thành các bước tuần tự như Hình 1. Thông tin trang nguồn được duy trì xuyên suốt các bước để có thể đối chiếu một đoạn JSONL với PDF ban đầu.



Hình 1: Luồng chuẩn bị dữ liệu và xử lý nhãn cấu trúc.

3 Chuẩn bị và trích xuất dữ liệu

3.1 Kiểm tra lớp văn bản

Mỗi PDF được kiểm tra số trang và lượng ký tự có thể trích xuất. Kết quả cho thấy hai tài liệu 03 và 05 có lớp văn bản, trong khi sáu tài liệu 01, 02, 04, 06, 07 và 08 là bản quét thuần ảnh. Do đó, việc chỉ sử dụng công cụ đọc PDF sẽ làm mất hoàn toàn nội dung của phần lớn tập dữ liệu.

Với hai PDF có lớp văn bản, nội dung được trích xuất trực tiếp bằng `pypdf`. Với sáu PDF ảnh, từng ảnh trang được đưa vào Tesseract sử dụng mô hình tiếng Việt `vie.traineddata`. OCR chỉ đóng vai trò fallback trên trang không có chữ, nhờ đó không làm suy giảm chất lượng của các trang đã có lớp văn bản tốt. Kết quả được lưu theo từng trang với ba thành phần: số trang PDF, văn bản thô và danh sách dòng theo đúng thứ tự xuất hiện.

3.2 Kiểm soát lỗi trích xuất

Một tài liệu bị xem là lỗi nếu cả trích xuất trực tiếp và OCR không tạo được nội dung đủ dùng. Pipeline dừng thay vì âm thầm sinh tệp rỗng. Với mỗi trang, số trang PDF được giữ nguyên để các bước làm sạch, phân tích cấu trúc và chia đoạn có thể truyền tiếp phạm vi `page_start`–`page_end`.

4 Làm sạch và chuẩn hóa văn bản

4.1 Loại bỏ nhiễu trình bày

Header và footer được phát hiện từ các dòng ngắn xuất hiện lặp lại tại ba dòng không rỗng đầu hoặc cuối của nhiều trang. Một dòng chỉ được xem là header/footer nếu xuất hiện ở ít nhất 60% số trang của tài liệu. Các số trang đứng độc lập ở vùng lề cũng được loại bỏ. Mỗi dòng bị xóa được ghi lại cùng số trang, vị trí, nội dung gốc và nguyên nhân, giúp quá trình làm sạch có thể kiểm tra lại.

Quy tắc loại nhiễu được thiết kế theo hướng bảo thủ. Số hiệu văn bản, ngày tháng, tỷ lệ phần trăm, số tiền, số Khoản và số Điểm không bị loại chỉ vì chúng chứa chữ số hoặc ký hiệu. Nội dung không khớp mẫu cấu trúc cũng không bị xóa tự động.

4.2 Chuẩn hóa ký tự và khoảng trắng

Văn bản được chuẩn hóa Unicode NFC, thay khoảng trắng không ngắt bằng khoảng trắng thông thường, loại ký tự điều khiển và gộp khoảng trắng liên tiếp. Khoảng trắng không cần thiết trước dấu câu được loại bỏ, nhưng dấu phẩy thập phân như `5,5%` vẫn được giữ nguyên. Các dòng được ghép ở bước tạo đoạn, đồng thời ranh giới trang vẫn được lưu bằng metadata.

5 Khôi phục cấu trúc và xử lý nhãn

5.1 Nhận diện cấu trúc phân cấp

Bộ phân tích đọc các dòng theo thứ tự và duy trì trạng thái cấu trúc hiện hành. Khi gặp nhãn *Chương*, *Mục* hoặc *Tiểu mục*, trạng thái tương ứng được cập nhật. Khi một *Điều* mới xuất hiện, Điều trước đó được kết thúc và nhận bản sao của đường dẫn cấu trúc hiện hành. Các dòng bắt đầu bằng số thứ tự được nhận diện là Khoản; các dòng bắt đầu bằng chữ cái và dấu ")" hoặc "." được nhận diện là Điểm.

Nội dung trước Điều đầu tiên được gắn nhãn `preamble`. Nội dung không nhận diện được cấp cấu trúc được giữ trong đơn vị hợp lệ gần nhất thay vì bị bỏ đi. Nhờ vậy, quá trình tạo nhãn không làm giảm độ bao phủ nội dung.

5.2 Các nhãn cấu trúc được thiết lập

Các nhãn cấu trúc được tạo theo hai mức: đường dẫn phân cấp của văn bản và đơn vị nội dung bên trong Điều. Bảng 1 trình bày đúng các nhãn được cài đặt trong parser của dự án.

Bảng 1: Các nhãn cấu trúc trong dự án.

Nhãn	**Kiểu/giá trị**	**Ý nghĩa và cách thiết lập**
`chapter`	object hoặc null	Chương hiện hành, gồm `number` và `title`. Số Chương chấp nhận số La Mã hoặc số Ả Rập; khi mở Chương mới, nhãn Mục cũ được đặt lại.
`section`	object hoặc null	Mục hoặc Tiểu mục hiện hành, gồm `number` và `title`. Hai cấp này được ánh xạ vào cùng trường `section`.
`article`	object hoặc null	Điều gốc, gồm `number` và `title`. Mọi chunk con của Điều đều giữ cùng object này; nội dung ngoài Điều nhận `null`.
`clause_ids`	list[string]	Danh sách số Khoản thực sự xuất hiện trong chunk, nhận diện từ mẫu số Ả Rập ở đầu dòng như `1.` hoặc `1)`.
`point_ids`	list[string]	Danh sách ký hiệu Điểm thực sự xuất hiện trong chunk, nhận diện từ chữ cái đầu dòng như `a)` hoặc `a.`; ký hiệu được chuyển về chữ thường.
`unit_type`	article, preamble	Nhãn nội bộ trước bước chunking. `article` là một Điều; `preamble` là nội dung có ý nghĩa trước Điều đầu tiên.

Các object `part`, `chapter`, `section` và `article` sử dụng cùng cấu trúc `{"number":`

..., "title": ...}. Khi một cấp không tồn tại trong văn bản, trường tương ứng được đặt là null, không suy diễn một nhãn giả. clause_ids và point_ids là danh sách rỗng nếu chunk không chứa Khoản hoặc Điểm được nhận diện.

5.3 Chuẩn hóa nhãn bị nhiễu do OCR

OCR có thể làm sai nhãn cấu trúc, ví dụ Điêù thành Điêì, hoặc đưa ký tự lề vào trước nhãn như | Điêù 14, _ Điêù 28 và l Tủ Điêù 23. Bộ phân tích áp dụng nhận diện dung sai cho các biến thể đã quan sát và cho phép tối đa tám ký tự nhiễu trước từ khóa Điều. Metadata vẫn được chuẩn hóa về số Điều đúng, còn văn bản OCR trong trường text được giữ lại để không che giấu chất lượng nguồn. Mọi trường hợp chuẩn hóa nhãn đều được ghi thành cảnh báo trong báo cáo QA.

5.4 Loại nhãn Điều giả

Một câu viện dẫn có thể bắt đầu bằng cụm Điêù 151 và khoản 4 Điêù 177... nhưng không phải tiêu đề Điều. Để hạn chế gán nhãn sai, một ứng viên tiêu đề phải có dấu phân cách ".", ":" hoặc "-" ngay sau số Điều. Sau ứng viên đầu tiên, số Điều phải tăng theo trình tự hợp lý; ứng viên lùi số hoặc nhảy xa bị giữ như nội dung của Điều hiện hành và được ghi cảnh báo Rejected Article-like reference. Cách xử lý này đồng thời loại được các mẫu hợp đồng hoặc quyết định đính kèm có hệ thống Điều riêng, tránh trộn nhãn của phụ lục vào cấu trúc chính.

6 Chia đoạn theo cấu trúc và gắn metadata

Đơn vị chia ưu tiên là một Điều hoàn chỉnh. Ngưỡng mặc định là 6.000 ký tự. Nếu một Điều vượt ngưỡng, các Khoản liên tiếp được đóng gói vào các đoạn riêng. Nếu một Khoản vẫn quá dài, ranh giới Điểm được ưu tiên; ranh giới câu chỉ được dùng khi đơn vị nhỏ hơn vẫn vượt ngưỡng. Tiêu đề Điều và metadata Điều gốc được giữ trong mọi đoạn con.

6.1 Schema metadata của mỗi chunk

Mỗi dòng JSONL là một object độc lập và luôn phát ra đầy đủ các trường trong Bảng 2. Trường không có giá trị dùng null hoặc danh sách rỗng thay vì bị lược bỏ, nhờ đó schema nhất quán giữa tám văn bản.

Bảng 2: Các trường metadata trong một dòng JSONL.

Trường	Kiểu dữ liệu	Mô tả
chunk_id	string	Định danh ổn định và duy nhất của chunk, lấy 20 ký tự hexa đầu của SHA-256.

Trường	Kiểu dữ liệu	Mô tả
`document_id`	string	Định danh tài liệu từ `doc-01` đến `doc-08`.
`title`	string	Tên đầy đủ của văn bản pháp luật.
`document_number`	string	Số, ký hiệu chính thức của văn bản, ví dụ `45/2019/QH14`.
`document_type`	string	Loại văn bản: `bộ luật`, `luật`, `nghị định` hoặc `thông tư`.
`source_file`	string	Đường dẫn tương đối đến PDF nguồn; dùng để truy vết và kiểm tra phạm vi dữ liệu.
`page_start`	integer	Trang PDF đầu tiên chứa nội dung chunk, đánh số từ 1.
`page_end`	integer	Trang PDF cuối cùng chứa nội dung chunk; luôn lớn hơn hoặc bằng `page_start`.
`chapter`	object/null	Nhãn Chương gồm `number`, `title`; `null` nếu không có.
`section`	object/null	Nhãn Mục/Tiểu mục gồm `number`, `title`; `null` nếu không có.
`article`	object/null	Nhãn Điều gốc gồm `number`, `title`; `null` đối với `preamble`.
`clause_ids`	list[string]	Các số Khoản có mặt trong riêng chunk này, theo thứ tự xuất hiện và không lặp.
`point_ids`	list[string]	Các ký hiệu Điểm có mặt trong riêng chunk này, theo thứ tự xuất hiện và không lặp.
`chunk_type`	string	Nhãn loại chunk: `preamble`, `article` hoặc `clause_group`.
`chunk_index`	integer	Vị trí chunk trong tài liệu, bắt đầu từ 1 và tăng liên tục.
`article_chunk_index`	integer/null	Vị trí chunk con trong Điều gốc; `null` nếu nội dung không thuộc Điều.
`text`	string	Nội dung đã làm sạch và chuẩn hóa dùng cho mô hình hoặc truy hồi.
`char_count`	integer	Số ký tự thực tế của trường `text`.
`token_estimate`	integer	Ước lượng nhanh bằng $\lceil \texttt{char_count}/3 \rceil$; không phải kết quả tokenizer của một mô hình cụ thể.
`split_reason`	string/null	Lý do chia: `null`, `max_size_clause` hoặc `max_size_sentence`.

Trường	Kiểu dữ liệu	Mô tả
processing_version	string	Phiên bản pipeline đã tạo chunk; bộ dữ liệu hiện tại sử dụng 1.0.0.

6.2 Ý nghĩa các nhãn chunk

Bảng 3: Tập giá trị nhãn chunk đang được triển khai.

Giá trị nhãn	Điều kiện gán
preamble	Nội dung trước Điều đầu tiên; article và article_chunk_index nhận null.
article	Một Điều được giữ nguyên vì không vượt ngưỡng kích thước; split_reason nhận null.
clause_group	Một phần của Điều dài sau khi được chia thành các nhóm; metadata Điều gốc được lặp lại để giữ ngữ cảnh.
max_size_clause	Giá trị của split_reason khi Điều dài được chia theo ranh giới các Khoản.
max_size_sentence	Giá trị fallback của split_reason khi một nhóm đơn lẻ vẫn quá dài và phải chia theo câu.
null	Không có thao tác chia; được biểu diễn bằng JSON null, không phải chuỗi ký tự "null".

Định danh chunk_id được tạo từ SHA-256 của định danh tài liệu, đơn vị cấu trúc, thứ tự đoạn con và nội dung; 20 ký tự hexa đầu tiên được sử dụng. Vì vậy, cùng dữ liệu và cấu hình sẽ sinh cùng định danh.

7 Kết quả và kiểm soát chất lượng

Bảng 4: Thống kê kết quả theo tài liệu.

ID	Trang	Ký tự sạch	Điều	Chunk	Dòng loại
doc-01	83	191,045	220	226	0
doc-02	122	235,737	115	132	23
doc-03	19	33,336	12	19	18
doc-04	14	29,658	5	10	1

ID	Trang	Ký tự sạch	Điều	Chunk	Dòng loại
doc-05	88	187,010	141	148	0
doc-06	52	116,614	45	49	5
doc-07	15	15,728	9	11	5
doc-08	83	179,182	64	73	65
Tổng	**476**	**988,310**	**611**	**668**	**117**

Kiểm tra tự động trên đầu ra xác nhận đủ tám định danh tài liệu, không có đường dẫn thuộc `data/tuychon`, không có `chunk_id` trùng và không có đoạn rỗng. Số Điều trong từng tài liệu tạo thành chuỗi liên tục: 1–220, 1–115, 1–12, 1–5, 1–141, 1–45, 1–9 và 1–64. Chỉ số đoạn con trong mỗi Điều cũng liên tục từ 1. Bộ kiểm thử gồm 22 trường hợp đã được chạy thành công.

Đầu ra được ghi qua tệp tạm và chỉ thay thế tệp đích sau khi tất cả dòng JSONL đọc lại hợp lệ. Ngoài tệp tổng hợp `legal_chunks.jsonl`, quy trình còn sinh tệp riêng cho từng tài liệu, dữ liệu thô/sạch theo trang và báo cáo QA ở định dạng JSON và Markdown.

8 Hạn chế của dữ liệu

Việc chuẩn hóa nhãn cấu trúc không đồng nghĩa với sửa toàn bộ lỗi OCR trong nội dung. Một số từ vẫn có thể bị nhận sai, chẳng hạn `tô᾽chức` thành `tô chức`, hoặc xuất hiện ký tự lề như ¬. Quy trình chủ động giữ nội dung OCR và chỉ chuẩn hóa biểu diễn metadata cần thiết cho phân đoạn. Cách làm này bảo đảm khả năng truy vết nhưng đòi hỏi bước rà soát hoặc sửa lỗi chính tả riêng nếu dữ liệu được dùng cho tác vụ nhạy cảm với từng ký tự.

Quy tắc tuần tự số Điều phù hợp với tám văn bản chính trong phạm vi đề tài. Khi áp dụng cho phụ lục có hệ thống Điều độc lập, văn bản sửa đổi có Điều mang hậu tố phức tạp, hoặc tập trích đoạn không bắt đầu từ cấu trúc chính, cần điều chỉnh trạng thái parser và metadata loại tài liệu.

9 Kết luận

Quy trình đã chuyển đổi tám PDF không đồng nhất về lớp văn bản thành tập JSONL có cấu trúc và khả năng truy vết. Việc kết hợp trích xuất trực tiếp với OCR theo trang giúp bao phủ toàn bộ dữ liệu; parser dung sai giúp phục hồi nhãn Điều bị nhiễu nhưng vẫn loại các câu viện dẫn và cấu trúc phụ dễ gây gán nhãn sai. Structure-aware chunking bảo toàn ngữ cảnh pháp lý tốt hơn chia đoạn cố định, đồng thời metadata thống nhất tạo điều kiện cho tìm kiếm, huấn luyện và đánh giá ở các bước tiếp theo.